

Universidade Regional Integrada do Alto Uruguai e das Missões — URI

Tópicos Especiais em Computação II – A (30-772)

Prof. Paulo Ricardo B. Betencourt

DecidAI

Sistema de Apoio à Decisão para Planejamento de Produção sob Incerteza

IA no Processo Decisório — Relatório Técnico

Integrantes do grupo:

Daniel Dewes • Cesario Stoquero • Samuel Maciel

Santo Ângelo — RS, junho de 2026

Sumário

Resumo Executivo

Este trabalho apresenta o **DecidAI**, um Sistema de Apoio à Decisão (SAD) que automatiza uma decisão organizacional recorrente e de alto impacto: **quanto produzir de cada produto a cada semana**, em uma agroindústria de médio porte sujeita a demanda incerta e recursos limitados. A solução encadeia quatro técnicas — previsão por Machine Learning, simulação de incerteza com Monte Carlo e Cadeias de Markov, otimização por Programação Linear (Simplex) e uma camada de explicabilidade (XAI) — entregando ao gestor não apenas uma recomendação, mas a **justificativa** por trás dela.

No cenário-base, o sistema recomenda um plano com lucro semanal ótimo de **R\$ 18.295,64**, identificando o **orçamento de produção como principal gargalo** (preço-sombra de R\$ 1,23 por real adicional). A análise de risco por Monte Carlo indica lucro médio esperado de R\$ 17.271,96, com piso de R\$ 14.678,60 nos 5% de cenários mais adversos.

1. Contextualização e Diagnóstico

1.1 Descrição e classificação do problema

A **AgroVale Alimentos** (empresa fictícia que representa o perfil de cooperativas agroindustriais da região do Alto Uruguai) produz cinco linhas de produtos a partir de uma mesma estrutura fabril compartilhada. Toda semana, a gestão precisa decidir o **mix de produção** — quanto fabricar de cada item — diante de uma demanda que oscila e de recursos finitos (horas de máquina, matéria-prima e capital de giro).

Hoje, essa decisão é tomada de forma intuitiva, com apoio de planilhas. O resultado é um ciclo de erros custosos: ora há **superprodução** (gerando perdas e custo de estocagem de produtos perecíveis), ora há **ruptura** (venda perdida e insatisfação do cliente).

Segundo a tipologia de Shimizu, trata-se de um problema **semiestruturado**: parte dele é estruturável (as restrições de capacidade e a função de lucro podem ser modeladas matematicamente), mas a demanda futura é incerta e o julgamento gerencial sobre prioridades (atender cliente estratégico, evitar perecíveis) introduz elementos não plenamente formalizáveis. É exatamente a faixa em que um SAD agrega mais valor — apoiando, sem substituir, o decisor.

1.2 Stakeholders e objetivos conflitantes

Os principais interessados na decisão possuem objetivos que competem entre si:

- **Produção:** busca estabilidade e ocupação eficiente das máquinas.
- **Vendas/Comercial:** quer estoque alto para nunca perder venda (nível de serviço).
- **Financeiro:** quer minimizar capital imobilizado em estoque e custo de produção.
- **Direção:** quer maximizar o lucro respeitando a capacidade instalada.

O conflito central é o **trade-off entre nível de serviço e custo**: estoque alto protege a venda mas imobiliza capital e arrisca perdas; estoque baixo reduz custo mas eleva o risco de ruptura. O SAD torna esse trade-off explícito e quantificável.

2. Modelagem do Processo Decisório

2.1 Variáveis consideradas

As **variáveis de decisão** são as quantidades a produzir de cada um dos cinco produtos na próxima semana. Os parâmetros de cada produto e as restrições da fábrica compõem o modelo:

Produto	Margem (R\$/un)	Horas-máq/un	Mat.-prima (kg/un)	Custo (R\$/un)	Demand a-base (un)
Suco Integral	4,50	0,020	1,2	3,00	1.200
Polpa Congelada	3,20	0,015	0,9	2,10	900
Geleia Artesanal	6,80	0,040	0,7	4,50	500
Doce em Barra	5,10	0,030	1,0	3,60	650
Néctar Light	2,90	0,012	0,8	1,80	1.100

Restrições semanais (capacidades):

- Horas de máquina disponíveis: 90 h
- Matéria-prima disponível: 4.000 kg
- Orçamento de produção (capital de giro): R\$ 12.000

2.2 Tratamento da incerteza

A incerteza de demanda é tratada em duas camadas complementares. Primeiro, o modelo de **Machine Learning** estima, além da demanda esperada, o **desvio-padrão dos resíduos**, que mede o erro típico da previsão. Segundo, uma **Cadeia de Markov** modela o regime de mercado em três estados — baixa, normal e alta demanda — com uma matriz de transição entre eles. A distribuição estacionária dessa cadeia informa a probabilidade de longo prazo de cada regime.

A **simulação de Monte Carlo** combina as duas fontes: para cada um dos 2.000 cenários, sorteia-se um regime (via Markov) e soma-se o ruído do modelo de ML, gerando uma distribuição completa de demanda por produto. Essa abordagem operacionaliza a distinção da disciplina entre **risco** (probabilidades conhecidas, capturadas pela matriz de Markov) e **incerteza** (a variabilidade residual da previsão).

3. Proposta de Solução com IA

3.1 Justificativa da técnica (por que IA, e não método puramente estatístico ou heurístico?)

Um modelo **puramente estatístico** (ex.: uma regressão de demanda) **prevê, mas não decide**: ele não considera as restrições de capacidade nem as margens, e portanto não produz um plano de produção acionável. Uma **heurística simples** (ex.: “produza a média histórica”) ignora tanto as restrições quanto a incerteza, levando justamente aos erros de superprodução e ruptura que se quer evitar.

A solução com IA agrega valor precisamente na **integração**: o ML transforma o histórico em previsão probabilística; o Monte Carlo+Markov converte a previsão em cenários de risco; e a otimização (Simplex) converte os cenários em uma **decisão ótima e factível**, que respeita

todas as restrições e maximiza o lucro. Nenhuma das técnicas isoladamente entrega esse resultado — é a orquestração que constitui o Sistema de Apoio à Decisão.

3.2 Arquitetura da solução

A arquitetura segue a estrutura clássica de SAD descrita por Shimizu, com três subsistemas — dados, modelos e interface — organizados em um pipeline sequencial:

- **Subsistema de Dados:** histórico de vendas (sintético) e tabela de parâmetros de negócio.
- **Subsistema de Modelos:** previsão (ML) → simulação (Monte Carlo + Markov) → otimização (Simplex) → explicação (XAI).
- **Subsistema de Interface:** dashboard executivo (Streamlit) para consulta e simulação de cenários what-if.

Fluxo: Dados → Previsão de demanda (ML) → Cenários de incerteza (Monte Carlo + Markov) → Decisão ótima (Simplex) → Explicação executiva (XAI) → Dashboard.

Implementação em **Python**: scikit-learn (RandomForest), NumPy (Monte Carlo e álgebra de Markov), PuLP/CBC (Simplex), SHAP e a API da Anthropic (Claude) para a explicação em linguagem natural, e Streamlit para a interface.

4. Implementação e Resultados

4.1 Dados utilizados

Foram usados **dados sintéticos reprodutíveis** (semente fixa), gerando aproximadamente três anos (156 semanas) de vendas semanais para os cinco produtos. Cada série combina nível-base, tendência linear, sazonalidade anual (52 semanas) e ruído aleatório de ~10%, reproduzindo padrões realistas de demanda sem expor dados sensíveis de uma empresa real.

4.2 Resultados — plano recomendado e análise de risco

Otimizando sobre a demanda esperada, o sistema retornou solução **ótima** com lucro de **R\$ 18.295,64** e o seguinte plano:

Produto	Unidades recomendadas
Suco Integral	1.368
Polpa Congelada	1.023
Geleia Artesanal	852
Doce em Barra	15
Néctar Light	1.033

Destaca-se que o **Doce em Barra** quase não é produzido: apesar de boa margem, seu consumo de horas de máquina e matéria-prima o torna pouco competitivo frente aos demais quando os recursos são escassos — um insight não óbvio que a otimização revela.

A simulação de Monte Carlo (2.000 cenários) avalia o **risco** desse plano:

Métrica de lucro	Valor (R\$)
Lucro esperado (demanda média)	18.295,64
Lucro médio simulado	17.271,96

Métrica de lucro	Valor (R\$)
Pior caso (percentil 5%)	14.678,60
Melhor caso (percentil 95%)	18.296,03

O lucro médio simulado fica abaixo do ótimo determinístico porque, em parte dos cenários, a demanda real cai abaixo do planejado, deixando produção sem venda. Ainda assim, mesmo no **pior caso (p5)**, o lucro permanece em R\$ 14.678,60 — evidência de que o plano é **robusto**.

4.3 Análise de sensibilidade

A leitura dos **preços-sombra** do Simplex revela quais recursos limitam o lucro:

Recurso	Usado	Disponível	Preço-sombra (R\$)
Horas de máquina	89,6 h	90,0 h	0,00 (há folga)
Matéria-prima	4.000 kg	4.000 kg	0,68
Orçamento	R\$ 12.000	R\$ 12.000	1,23

O **orçamento é o gargalo dominante** (cada R\$ 1 adicional gera R\$ 1,23 de lucro), seguido da matéria-prima (R\$ 0,68). As horas de máquina sobram, logo investir em mais capacidade de máquina não traria retorno. Variando o orçamento:

Variação do orçamento	Orçamento (R\$)	Lucro ótimo (R\$)
-20%	9.600	14.700,24
-10%	10.800	16.500,24
base	12.000	18.295,64
+10%	13.200	18.378,94
+20%	14.400	18.378,94

O resultado mostra um efeito de **retornos decrescentes**: aumentar o orçamento eleva o lucro até cerca de +10%, ponto em que outro recurso (a matéria-prima) passa a restringir, e o lucro estabiliza em R\$ 18.378,94. Esse tipo de leitura orienta diretamente onde a empresa deve investir.

4.4 Explicabilidade (XAI)

Atendendo à recomendação de Shimizu de que um gestor não aceita uma decisão de “caixa preta”, a solução justifica a recomendação em três níveis:

- **Preços-sombra (Simplex):** explicam por que o plano é ótimo e onde está o gargalo — explicabilidade nativa da Pesquisa Operacional.
- **Importância de variáveis (SHAP):** explica o que dirige a previsão de demanda (sazonalidade, tendência, vendas recentes).
- **Linguagem natural (LLM):** o modelo Claude traduz os números em um parágrafo executivo em português, pronto para o comitê.

5. Conclusões e Limitações

5.1 Valor gerado

O DecidAI converte uma decisão antes intuitiva em um processo **rastreável, ótimo e explicável**. Ele entrega: (i) um plano de produção que maximiza o lucro respeitando todas as restrições; (ii) uma medida explícita de risco; (iii) a identificação do gargalo que mais limita o resultado; e (iv) uma justificativa em linguagem de negócio. Em síntese, transforma dados em **decisão defensável** — que é o objetivo central de um SAD.

5.2 Limitações éticas, técnicas e de contexto

- **Dados sintéticos:** a prova de conceito usa dados gerados; choques reais de mercado (clima, preço de insumos) não estão representados.
- **Viés do histórico:** o modelo de ML reproduz padrões do passado; se o histórico contém vieses (ex.: campanhas pontuais), eles se propagam à previsão.
- **Linearidade do Simplex:** o modelo assume custos e consumos lineares, ignorando ganhos de escala e custos fixos de setup.
- **Decisão sobre valor esperado:** a otimização usa a demanda média; uma extensão natural é a programação estocástica de dois estágios, que decide considerando todos os cenários simultaneamente.
- **Fator humano (Shimizu):** a decisão é também política e organizacional; o sistema apoia, mas a palavra final permanece com o gestor.

5.3 Próximos passos

- Substituir o RandomForest por modelos de série temporal mais ricos e validar com dados reais.
- Incluir a alocação a clientes/centros de distribuição no modelo de otimização.
- Migrar para programação estocástica de dois estágios para decidir sob incerteza explícita.
- Integrar o SAD ao ERP da empresa para execução automática semanal.

6. Divisão de Tarefas

O desenvolvimento foi organizado por camadas da arquitetura: cada integrante respondeu por um eixo técnico do pipeline, com integração contínua entre as partes.

Integrante	Responsabilidades principais	Artefatos
Daniel Dewes	Camada de dados e previsão (ML); orquestração do pipeline ponta a ponta	data_gen.py, forecast.py, pipeline.py
Cesario Stoquero	Tratamento da incerteza (Monte Carlo + Markov) e otimização (Simplex); análise de sensibilidade	simulation.py, optimization.py
Samuel Maciel	Explicabilidade (XAI) e interface executiva (dashboard Streamlit)	xai.py, app/dashboard.py

A **redação do relatório**, a **preparação da apresentação** e a **revisão dos resultados** foram conduzidas em conjunto pelos três integrantes.